

PU 合成性评分器性能与来源审计

本报告是独立审计产物，不修改论文正文或补充信息。审计对象是服务器上的 `clscore_all.csv`（评分器 A）和 `clscore_b_all.csv`（评分器 B）所对应的两个 PU-learning 管线。报告中的 AUC 全部来自保存的逐袋日志；它们是验证集指标，不是合成失败的真实识别率。

结论先行

评分器 A 和 B 使用相同的 50 个 PU bag 划分和相同的 out-of-bag（OOB）掩码，但编码器和训练头不同，因此可以作为两种结构表示下的互补排序意见：

输出标签	模型	50 袋 best validation ROC-AUC（均值 ± 样本标准差）	范围
CGCNN-PU OOB	从头训练的晶体图卷积网络（CGCNN）	0.976538 ± 0.000763	0.9749–0.9781
MatterSim-1M-MLP-PU OOB	冻结 MatterSim-v1.0.0-1M 表征 + MLP PU head	0.946566 ± 0.000942	0.9443–0.9486

这里的验证标签是“实验正结构”对“按该 bag 从未标注池抽取的伪负结构”。源数据没有观察到的难合成/失败合成负标签，也没有 untouched independent test 文件。因此不能把上表称为 test accuracy、真实可合成性准确率或对失败合成的 召回率。

两个分数究竟是什么

A : CGCNN-PU OOB

03_train_bags.py 的模型说明给出 CGCNN 的 3 个卷积层、64 维原子特征、128 维晶体特征和二分类头（文件第 2–13 行）；每个 bag 在其验证集上计算 ROC-AUC 并保存当前最佳 checkpoint（第 50–62、109–118 行）。模型构造在 pu_common.py 第 244–258 行，调用 CrystalGraphConvNet 的参数为 atom_fea_len=64, n_conv=3, h_fea_len=128, n_h=1。

04_predict_clsore.py 第 2–6、51–69 行定义了全池分数：对结构没有被抽入某个 bag 的模型概率取平均，即

$$[A(x) = \{b:x_b\}P_b(y=1|x).]$$

这就是 OOB 全池排序分数；OOB 不是“独立测试集”的同义词。

B : MatterSim-1M-MLP-PU OOB

07_embed_pu_head.py 第 2–23 行说明 B 使用冻结的 MatterSim-v1.0.0-1M 编码器和小型 MLP 头，不微调势函数；第 282–287 行给出头部结构 128 → 256 → 256 → 2（SiLU、Dropout、LogSoftmax）。第 301–325 行显示训练/验证行沿用同一 bag 划分，并以验证 ROC-AUC 选择最佳头；第 329–357 行用相同的 bag-membership 掩码写出 clsore_b_all.csv。

11_compare_scorers.py 第 4–13 行将 A/B 描述为不同结构归纳偏置的两个评分器，并指出二者共享 OOB 掩码。共享掩码支持逐结构配对比较和共识筛选，但不等于两个分数已完成概率校准。

B 的 MatterSim 预处理会跳过少量无序、超大晶胞或近重合原子结构（实现见 07_embed_pu_head.py 第 211–230 行）。因此当前全池文件的覆盖并非完全相同：clsore_all.csv 有 8,109,897 个未标注结构，clsore_b_all.csv 有 8,108,676 个，B 少 1,221 个。对 A/B 做逐结构比较时应先取共同 ID，不能把缺失行当作低分或负例。

划分协议与可复核计数

02_split_bagging.py 第 2–13 行和第 38–56 行规定：20% 实验正例固定为各袋共同的验证正例；每袋从未标注池抽取与正例等量的伪负例，再取其中 20% 作为该袋验证伪负例，其余用于训练；每袋未被抽中的未标注结构才进入该袋 OOB 评分。

服务器重算生成的 `remote/protocol_audit.json` 给出本次快照的精确计数：

- 池共 8,208,887 行，其中实验正例 98,990 行、未标注行 8,109,897 行；
- 50 个 bag，每袋验证 39,596 行（19,798 正例 + 19,798 伪负例），训练 158,384 行；
- 固定正例验证集在 50 袋间完全相同，训练/验证交集为 0；
- 审计明确写入 `independent_test_available: false`，原因是没有真实负例或 `untouched test` 文件。

逐袋日志原文及行号索引保存在 `remote/log_line_provenance.tsv`。A 日志是 `/data1/home/hzxy10/csllm/logs/train_200535_1.out`、`train_200536_*.out` 和 `train_200537_*.out` 中的 `DONE best vAUC` 行；B 日志是 `/data1/home/hzxy10/csllm/logs/headB_200736.out` 第 1–50 行。

图和表的含义

`figure_cgcnn_pu_validation_performance.*` 与 `figure_mattersim_lm_mlp_pu_validation_performance.*` 分别展示 50 个 bag 的 best validation ROC-AUC 分布（PNG、PDF、SVG 三种格式）。图中明确写出：

1. 标签为实验正例与抽样伪负例；
2. 数值是 validation ROC-AUC，而不是 independent-test ROC-AUC；
3. OOB 只表示全池评分时的 bag 外平均。

逐袋原始数值在 `per_bag_validation_auc.csv`，机器可读汇总在 `model_summary.json`，文件哈希和来源脚本在 `manifest.json`。

原管线 README（`script/pu_screening_v2/README.md` 第 42–48 行）写成 $A\ 0.9766 \pm 0.0016$ 、 $B\ 0.9466 \pm 0.0022$ 。这两个 $\pm$ 数值分别等于逐袋最小–最大范围的一半（A 为 0.0016，B 为 0.00215，四舍五入为 0.0022），不是逐袋样本标准差。本包同时给出明确标注为 SD 的样本标准差，避免混用两种摘要口径。

是否应该把 A、B 取平均

不应把未经校准的原始 `CLscore_A` 和 `CLscore_B` 做算术平均后称为新的“合成概率”或“综合准确分数”。虽然二者都落在 0–1 区间并共享 OOB 掩码，A 是 CGCNN 分类头输出，B 是 MatterSim 表征上的另一个 MLP 分类头；PU 伪负标签、正例比例、表示尺度和校准误差都可能不同。当前证据只支持：

- 分别报告 A 与 B 的排序和验证表现；

- 用两个低分尾部的交集作为保守共识 (`08_consensus_negatives.py` 第 105–115 行)；或
- 先在同一、真正独立且带可靠标签的数据上做校准/分位数变换，再定义有明确权重的组合分数。

现有脚本在 `rank mode` 中用 `CLscore_A + CLscore_B` 排序候选（第 9、133–138 行）。这应被描述为工程上的 `rank aggregator`，而不是由物理化学或概率模型推导出的平均值。

异步重算状态

为尝试生成原始预测的 ROC/PR 曲线，服务器作业 209577 读取了 A 的 50 个 `packed-graph bag` 并全部完成，但随后在进入 B `embedding` 阶段前无日志进展。运行约 19 分钟时 `sstat` 显示 `batch CPU` 为 0、`RSS` 约 7 MB，已安全取消以避免继续占用 GPU。因而本包不伪造 PR-AUC 或原始 ROC/PR 曲线；当前交付的指标和图完全来自可追溯的逐袋验证日志。